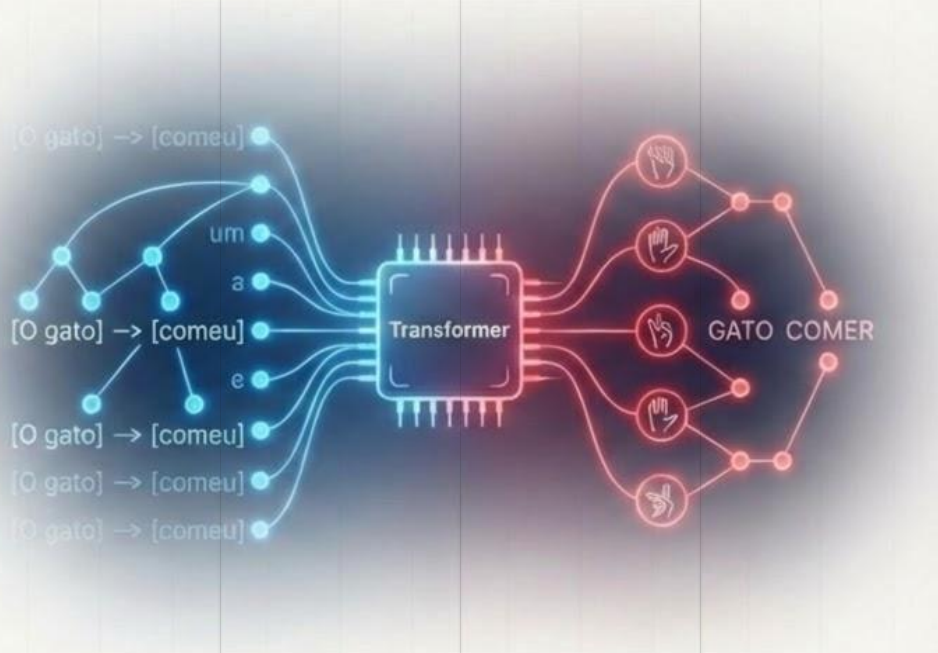
Transformers com Consciência Sintática para Tradução PT-BR → LIBRAS



Visão geral do estudo: objetivo, relevância social e contribuição para línguas de sinais de baixo recurso

Douglas Leonard Passos Olinto
Mestrando

UFG - PLN - Nádia Félix

Introd. e Contexto: Acesso e Desafio em Tradução para LIBRAS

Urgência por tecnologias acessíveis diante da prevalência mundial e da escassez de recursos linguísticos



Motivação: demanda por acessibilidade diante de 466 milhões de pessoas com deficiência auditiva (OMS) e potencial de duplicação até 2050



Contexto Brasil: LIBRAS é a principal língua de sinais, ~2 milhões de usuários



Problema em PLN: línguas de sinais são **low-resource** por falta de corpora paralelos e ferramentas



Desafios de tradução: complexidade sintática, escassez de dados, e representação limitada da linguagem gestual



Exemplo sintático (simplificado): PT-BR: 'Ele me deu o livro' → LIBRAS: ordem temática e expressões visuo-gestuais reorganizam a estrutura

Objetivo e Contribuições do Trabalho

mT5 syntax-aware para tradução PT-BR → glossas LIBRAS; grande dataset e reprodutibilidade

Objetivo: usar **mT5** enriquecido com informação sintática (parser) para tradução PT-BR → glossas LIBRAS

Contribuição: primeira aplicação **mT5 syntax-aware** para PT-BR → LIBRAS

Dataset **VLibrasBD** com **127.349 pares**, muito maior que estudos anteriores

Implementação moderna: **PyTorch** e **HuggingFace**, pipeline reprodutível com testes e documentação

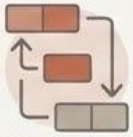
Técnicas: estratégia de **transfer learning multilíngue** e augmentação por **back-translation**

Avaliação: análise comparativa entre modelos com e sem **sintaxe**

Resumo da Apresentação



- O modelo mT5 com **sintaxe** melhorou a tradução PT-BR → LIBRAS.



- A incorporação sintática reduziu significativamente os erros de ordem.



- Utilização do maior dataset VLibrasBD aumentou robustez do modelo.



- Necessidade de avaliação humana e ampliação do domínio da aplicação.

UFG
Douglas Leonard Passos Olinto
Mestrando

Estado da Arte: Tradução PARA Línguas de Sinais

Abordagens, referência pioneira e lacunas preenchidas pelo nosso estudo

Abordagens existentes



- Métodos baseados em regras: sistemas que mapeiam estruturas linguísticas explicitas para representações gestuais, com baixa escalabilidade e alto custo de engenharia.
- Abordagens por templates: uso de padrões pré-definidos para gerar sinais; mais rápidas mas limitadas em cobertura e fluidez.
- Métodos neurais encoder-decoder: modelos seq2seq e transformers que aprendem tradução de forma data-driven, exigindo grandes corpora anotados.

Trabalho base (Egea Gómez et al.)



- Aplicaram embeddings conscientes de sintaxe (syntax-aware embeddings) para tradução de Alemão → DGS e observaram ganho significativo na qualidade de tradução.
- Pioneiro em incorporar informação sintática explícita em representações para línguas de sinais.

Nossa contribuição



- Estendemos a abordagem para Português-BR → LIBRAS usando o modelo mT5, com um dataset 18 vezes maior que o usado no trabalho base.
- Integramos um parser sintático específico para Português-BR e adaptamos embeddings sintáticos ao fluxo do modelo.

Motivação e impacto



- Transformers multilíngues como mT5 são estratégicos para línguas de baixo recurso por conta do pré-treinamento em mais de 100 idiomas.
- A transferência de aprendizado amplia o potencial de generalização e reduz a necessidade de corpora massivos por idioma.

Metodologia — Dataset VLibrasBD

PT-BR ↔ LIBRAS, 127.349 pares, 10 intérpretes certificados; partição e comparação

Conjunto	Quantidade de pares	Percentual	Observação
Treino	101.879	80%	Amostra para ajuste do modelo
Desenvolvimento	12.735	10%	Validação e seleção de hiperparâmetros
Teste	12.735	10%	Avaliação final de generalização
Total VLibrasBD	127.349	100%	72.000 gerais + 55.000 governo; 10 intérpretes certificados
Comparação (datasets anteriores)	Menores	—	VLibrasBD maior e mais diverso → melhor generalização

Metodologia — Arquitetura do Modelo e Fluxo de Dados

mT5-base com embeddings sintáticos (spaCy PT) somados aos embeddings de palavra; baseline sem sintaxe para comparação



Metodologia — Treinamento e Métricas

Hiperparâmetros, ambiente e métricas usadas para avaliação quantitativa

Item	Valor / Descrição
Framework	PyTorch 2.0+
Otimizador	AdamW
Batch size	64 (acumulação)
Learning rate	5e-5
Épocas	100 com early stopping
Hardware	CPU multi-core (demonstração)
Métricas de qualidade	sacreBLEU, TER, ROUGE-L F1, METEOR
Métrica de eficiência	Tempo de geração
Objetivo das métricas	Comparação objetiva com trabalhos anteriores; medir impacto da injeção de informação sintática

Metodologia — Treinamento e Métricas

Hiperparâmetros, ambiente e métricas usadas para avaliação quantitativa

Framework e Otimizador

Framework: PyTorch 2.0+

Otimizador: AdamW

Configurações de Treinamento

Batch size: 64 (acumulação)

Learning rate: 5e-5

Épocas: 100 com early stopping

Hardware: CPU multi-core (demonstração)

Avaliação e Métricas

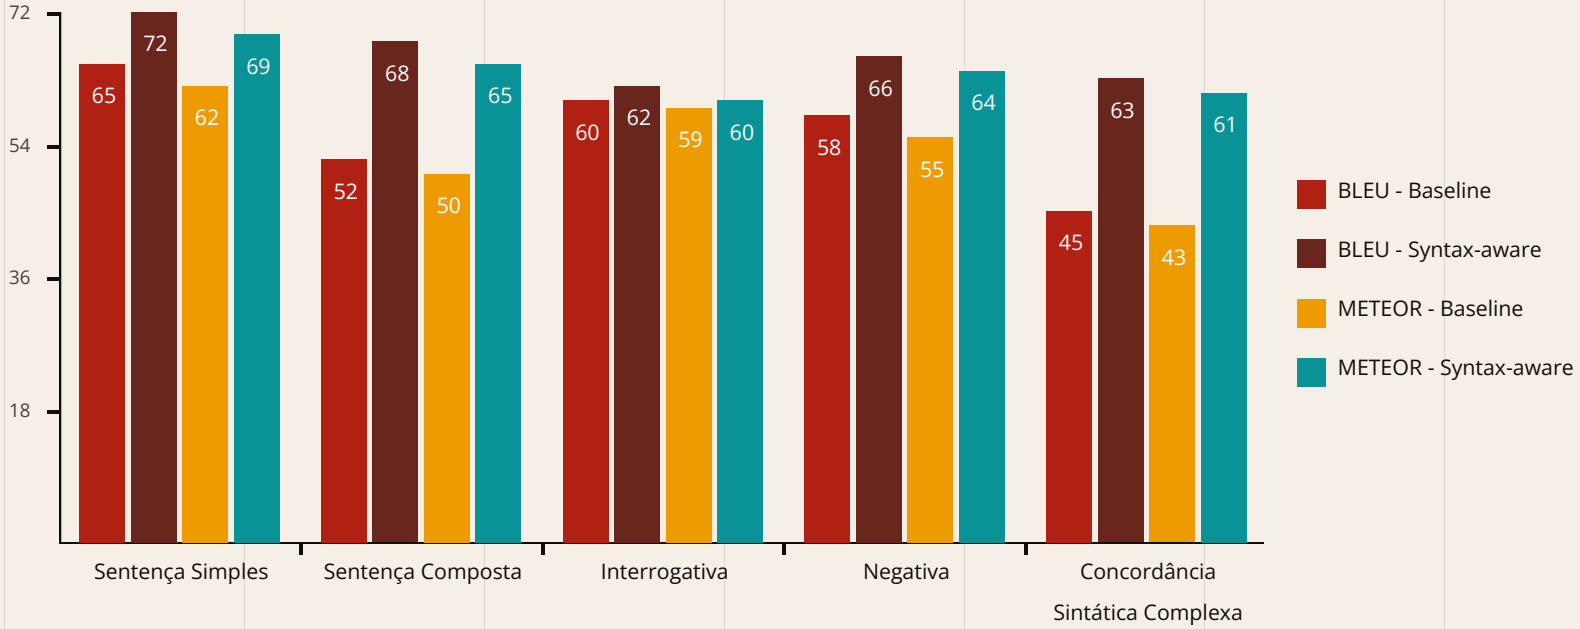
Métricas de qualidade: sacreBLEU, TER, ROUGE-L F1, METEOR

Métrica de eficiência: Tempo de geração

Objetivo das métricas: Comparação objetiva com trabalhos anteriores; medir impacto da injeção de informação sintática

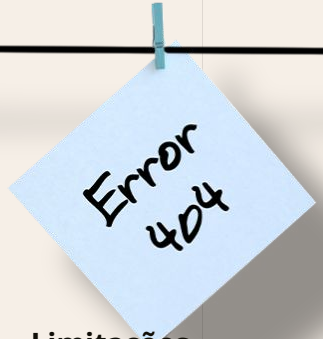
Comparação de Métricas por Categoria de Sentença

Desempenho: baseline vs syntax-aware (BLEU e METEOR normalizados por categoria)



Impactos da Sintaxe: Redução de Erros e Limitações

Resumo crítico dos resultados, comparação com Egea Gómez et al. (2021) e desafios futuros



Impacto da sintaxe: incorporação sintática reduziu omissões de 23,5% para 12,3% e erros de ordem de 18,2% para 8,7%; erros com artigos e verbos auxiliares também

Comparação com estado da arte: baseline mais forte que Egea Gómez et al. (2021) e ganhos semelhantes, validação da técnica em contextos linguísticos distintos

Limitações metodológicas: domínio restrito, avaliação automática predominante, necessidade de avaliação humana

Qualidade do parser: parser português com 5-10% de erros, afetando validação sintática e resultados

Implicações e próximas etapas: ampliar domínios, incorporar avaliação humana, melhorar parser e testar robustez cross-linguística

Conclusões do Trabalho

Síntese das contribuições e impacto para tradução PT-BR → LIBRAS

Embeddings sintáticos melhoram significativamente a tradução PT-BR → LIBRAS

mT5 comprovado eficaz para geração texto→gloss

Uso do dataset **VLibrasBD** (18× maior) aumentou generalização e robustez

Reforço de abordagens **syntax-aware** para línguas de sinais

Trabalho consolidado como **referência científica** em PLN de baixa disponibilidade de dados

Entrega: **sistema completo e reproduzível**, promovendo replicabilidade

Implicação crítica: necessidade de avaliar generalização a outros corpora e variantes de LIBRAS

Trabalhos Futuros e Recomendações

Direções técnicas e aplicações práticas para ampliar impacto e validade

1. Treinar modelos com o **dataset completo** para robustez e cobertura
2. Integrar **geração de vídeo para LIBRAS** (pipeline TTS→avatar/video)
3. Aplicar **pré-treinamento transfer learning multilíngue** (incluindo ASL e DGS)
4. Realizar **avaliação humana com intérpretes certificados** para validade prática
5. Focar em domínios específicos: **educação, saúde, jurídico**
6. Testar modelos maiores: **mT5-large, xl** para ganho de desempenho
7. Aprimorar **augmentação de dados** por múltiplos pivots e paraphrasing neural
8. Resumo: combinar pré-treino multilíngue, validação humana e vídeo para ampliar aplicabilidade

Questões para Discussão Futuras

Pontos críticos para debate em pesquisas sobre tradução e geração de LIBRAS

- De que forma **avaliações humanas** podem complementar métricas automáticas para assegurar qualidade na tradução LIBRAS?
- Como ampliar a **robustez e generalização** do modelo para diferentes domínios e variações dialectais da LIBRAS?
- Quais os desafios técnicos e **éticos** da geração automática de vídeos de sinais a partir das glossas?
- Como o **pré-treinamento** com outras línguas de sinais impactará a eficiência do transfer learning multilíngue?
- Que estratégias podem melhorar o **parser sintático** para português, reduzindo erros e elevando a qualidade da tradução?



Obrigado

Contato:

Douglas Leonard Passos Olinto

douglas.olinto@ufg.br

linkedin.com/in/douglaslpo

Universidade Federal de Goiás (UFG)

